UNIFIED CALIBRATION FRAMEWORK for Trustworthy AI

Literature Review & Phase-I Plan

PI: NCS. ThS. Dung Cam-Quang
Team: Hac Minh-Quan, Huynh Hoang-Anh, Tran Tien-Dat
Advisor: Dr. Ha Xuan-Son

Faculty of Computer Science & Engineering
Ho Chi Minh City University of Technology (HCMUT) — VNU-HCM
In collaboration with Viettel

June 2026

VIETNAM NATIONAL UNIVERSITY HO CHI MINH CITY
HO CHI MINH CITY UNIVERSITY OF TECHNOLOGY

Executive Summary

Mục tiêu báo cáo: tóm tắt phần đã literature review, phần đã chuẩn bị cho Phase 1, định hướng triển khai, và future plan.

- **Literature review:** calibration cho Narrow AI, LLMs, và VLMs; tập trung vào đo lường sai lệch confidence–accuracy và cách hiệu chỉnh.
- **Chuẩn bị:** xác định metrics, baseline methods, datasets/benchmarks, pipeline thí nghiệm, và các module cần xây dựng.
- **Định hướng:** xây dựng Unified Calibration Framework (UCF) theo hướng modular, đo được, tái lập được, mở rộng được sang LLM/VLM.
- **Future plan:** giữ lộ trình Phase 2–3 cho LLM calibration, VLM calibration, distribution shift và ứng dụng Viettel.

Literature Review 1: Narrow AI Calibration

Vấn đề chính: neural networks hiện đại thường đạt accuracy cao nhưng confidence không phản ánh đúng xác suất đúng.

Nhóm phương pháp đã review:

- **Post-hoc calibration:** Temperature Scaling, Isotonic Regression, Beta Calibration, Bayesian Binning.
- **Training-time calibration:** Label Smoothing, Confidence Penalty, MMCE, Focal Loss, Mixup, Deep Ensembles, MC Dropout.
- **Metrics:** ECE, Adaptive ECE, MCE, Brier Score, NLL, reliability diagram, selective-risk curve.

Kết luận review: Temperature Scaling là baseline mạnh, đơn giản, ít ảnh hưởng accuracy; các phương pháp adaptive/ensemble hữu ích khi gặp distribution shift.

Literature Review 2: LLM Calibration

Vấn đề chính: LLM có thể trả lời rất tự tin nhưng sai; RLHF và black-box API làm token probability không còn là tín hiệu calibration đáng tin tuyệt đối.

Nhóm hướng tiếp cận đã review:

- **Token/log-prob based:** dùng xác suất chuỗi sinh ra khi có logit hoặc log-prob access.
- **Verbalized confidence:** yêu cầu mô hình tự ước lượng độ tin cậy bằng prompt.
- **Self-consistency:** lấy nhiều mẫu trả lời, dùng mức đồng thuận làm confidence signal.
- **RAG grounding:** kiểm tra độ bám nguồn và chất lượng retrieval để giảm hallucination.
- **APRICOT-style:** embedding câu hỏi, clustering, tính accuracy theo cụm, huấn luyện auxiliary calibrator.

Literature Review 3: VLM Calibration

Vấn đề chính: VLM có hai nguồn bất định: tín hiệu thị giác và tín hiệu ngôn ngữ; câu trả lời mạch lạc có thể che giấu uncertainty từ ảnh.

Nhóm hướng tiếp cận đã review:

- **Distance-Aware Calibration:** dùng khoảng cách embedding text/visual để điều chỉnh confidence.
- **Cross-modal decomposition:** tách confidence thành thành phần vision và language.
- **Attention/grounding check:** dùng cross-attention hoặc grounding score để phát hiện câu trả lời không bám ảnh.
- **Perturbation-based uncertainty:** đo variance khi thay đổi ảnh, prompt, hoặc sampling strategy.

Kết luận review: VLM cần calibration theo từng modality, không nên chỉ dùng softmax hoặc text confidence cuối cùng.

Metrics, Baselines, Benchmarks

Metrics library cần xây dựng:

- ECE equal-width, Adaptive ECE/equal-mass, MCE, Brier Score, NLL.
- Reliability diagram trước/sau calibration và selective-risk curve.

Baseline thí nghiệm đã xác định:

- Narrow AI: raw softmax, Temperature Scaling, Isotonic Regression, Beta/Dirichlet-style calibration.
- LLM: token probability, verbalized confidence, self-consistency, APRICOT-style calibrator.
- VLM: uncalibrated CLIP/LLaVA, DAC, cross-modal confidence decomposition.

Benchmarks: CIFAR-100, ImageNet-C, MMLU, TruthfulQA, HaluEval, POPE, VQA-v2, SEED-Bench.

Phase 1 Implementation Assets

Narrow AI pipeline:

- Quy trình extract logits từ CNN/ViT trước softmax.
- Tối ưu temperature trên validation set bằng NLL.
- So sánh calibration trước/sau bằng cùng bộ metrics.

LLM/VLM foundation:

- Thiết kế embedding pipeline cho câu hỏi bằng Sentence-BERT.
- Chuẩn bị clustering semantic groups bằng HDBSCAN cho APRICOT-style calibration.
- Xác định cách thu correctness labels, self-consistency score, grounding score.
- Chuẩn bị hướng tích hợp cross-attention/visual uncertainty cho VLM.

Định Hướng: Unified Calibration Framework

Ý tưởng chính: xây dựng UCF như một framework thống nhất nhưng có module riêng cho từng loại mô hình.

- **Metrics layer:** chuẩn hóa cách đo calibration trên mọi architecture.
- **Calibration layer:** triển khai post-hoc và training-time methods theo interface chung.
- **Model-specific layer:** Narrow AI dùng logits; LLM dùng generation confidence; VLM dùng cross-modal signals.
- **Monitoring layer:** theo dõi distribution shift, drift, và kích hoạt recalibration khi cần.
- **Deployment layer:** hỗ trợ reject option, conformal prediction, human-in-the-loop cho case rủi ro cao.

Phase 1 Plan: June–July

Task 1 — UCF-Metrics:

- Implement ECE variants, MCE, Brier Score, NLL, visualization utilities.

Task 2 — Narrow AI Baseline:

- Extract logits, implement Temperature Scaling, compare post-hoc baselines, evaluate OOD robustness.

Task 3 — LLM/VLM Preparation:

- Build SBERT embedding pipeline, HDBSCAN clustering, correctness aggregation, resource request for Phase 2.

Deliverables cuối Phase 1: metrics library, baseline notebooks/scripts, reliability plots, LLM/VLM calibration design document.

Future Developments

Phase 2-3 Research Extensions:

- Full APRICOT implementation and LLM calibration at scale
- VLM multi-modal calibration on CLIP and LLaVA
- Extreme distribution shifts and continual learning scenarios

Practical Applications in Industry:

- Medical diagnosis systems with confidence-aware recommendations
- Financial risk assessment with uncertainty quantification
- Autonomous systems with calibrated rejection and human-in-the-loop mechanisms

Viettel Partnership Goals: Integration with production systems, real-world distribution shift datasets, and deployment best practices documentation.